

PROJET FINAL – 2025/2026

Audit de biais d'un modèle de classification

Étude complète du dataset COMPAS ProPublica

Module : Deep Learning / Fairness algorithmique
Filière : Intelligence Artificielle et Cybersécurité

Réalisé par KPADENOU Kossi Roland

Dépôt Git `git@github.com:RolandKHax/
Audit-de-biais.git`

Année universitaire 2025–2026

Juin 2026

Résumé

Ce rapport explique, étape par étape, comment auditer les biais d'un modèle de classification sur le dataset réel **COMPAS** publié par ProPublica. L'objectif n'est pas seulement d'obtenir un modèle performant : il faut aussi comprendre si ses erreurs touchent certains groupes plus que d'autres.

Ce qui a été réalisé

- Utilisation du dataset réel `compas-scores-two-years.csv`, avec **6172 lignes** après nettoyage.
- Étude des attributs sensibles **race** et **sex**.
- Entraînement de trois familles de modèles : régression logistique, forêt aléatoire et MLP.
- Comparaison des modèles avec et sans attributs sensibles dans les variables d'entrée.
- Mesure de la performance classique : accuracy, précision, rappel, F1-score et ROC-AUC.
- Mesure de la fairness : demographic parity, disparate impact, equalized odds, equal opportunity, TPR, FPR et selection rate.
- Tests de mitigation : reweighting, resampling, Fairlearn, seuils par groupe et adversarial debiasing avec PyTorch.
- Production de scripts, notebooks, tableaux, figures, rapport PDF et présentation PDF.

Idée simple : un modèle peut avoir une bonne note globale et rester injuste. Par exemple, si deux groupes obtiennent presque la même accuracy mais qu'un groupe reçoit beaucoup plus de faux positifs, le modèle peut créer une injustice concrète.

Conclusion en une phrase

Sur COMPAS, la performance globale est correcte, mais les écarts de fairness sur **race** sont importants : il ne faut donc pas déployer ce type de modèle sans audit, documentation, supervision humaine et suivi régulier.

Table des matières

Résumé	i
Table des matières	iii
Liste des figures	iv
Liste des tableaux	v
Introduction générale	vi
1 Comprendre le problème	1
1.1 Qu'est-ce qu'un modèle de classification ?	1
1.2 Les quatre types de résultats	1
1.3 Performance globale et fairness	2
2 Dataset COMPAS	3
2.1 Source et taille	3
2.2 Variables importantes	4
2.3 Nettoyage réalisé	4
2.4 Limites du dataset	4
2.5 Analyse exploratoire	4
3 Méthodologie expérimentale	6
3.1 Pipeline général	6
3.2 Découpage train, validation et test	6
3.3 Modèles comparés	6
3.4 Deux politiques de features	6
3.5 Répétitions multi-seeds	7
3.6 Intervalles de confiance	7
4 Métriques utilisées	8
4.1 Métriques de performance	8
4.2 Métriques de fairness	8
4.3 Lecture des écarts	9
5 Résultats des modèles baseline	10
5.1 Résumé global	10
5.2 Baseline principale retenue	10
5.3 Matrices de confusion et courbes ROC	11
6 Analyse détaillée de fairness	12
6.1 Résultats par groupe	12
6.2 Lecture des résultats pour race	12
6.3 Lecture des résultats pour sex	12
6.4 Résumé des écarts fairness	13

7	Méthodes de mitigation	14
7.1	Pourquoi atténuer les biais	14
7.2	Familles testées	14
7.3	Résultats des mitigations	14
7.4	Interprétation	15
8	Discussion critique	17
8.1	Pourquoi il n'existe pas une seule fairness	17
8.2	Pourquoi l'accuracy peut tromper	17
8.3	Limites techniques	17
8.4	Limites éthiques	17
9	Recommandations	18
9.1	Recommandations techniques	18
9.2	Recommandations de gouvernance	18
9.3	Recommandation finale	18
10	Conclusion	19
A	Annexes techniques	20
A.1	Structure finale du projet	20
A.2	Commandes de reproduction	20
A.3	Glossaire très simple	21

Table des figures

2.1	Distribution des labels par attribut sensible	5
5.1	Matrices de confusion par groupe	11
5.2	Courbes ROC par groupe	11
7.1	Comparaison fairness avant et après mitigation	15

Liste des tableaux

1.1	Lecture simple d'une matrice de confusion	1
1.2	Différence entre performance et fairness	2
2.1	Fichiers de données utilisés	3
2.2	Variables centrales de l'audit	4
3.1	Modèles entraînés	6
4.1	Métriques classiques	8
4.2	Métriques de fairness en langage simple	8
4.3	Lecture qualitative des écarts de fairness	9
5.1	Baselines multi-seeds : moyenne et écart-type	10
5.2	Baseline principale	10
6.1	Métriques détaillées par groupe	12
6.2	Écarts principaux de fairness sur la baseline	13
7.1	Familles de mitigation comparées	14
7.2	Comparaison des méthodes de mitigation	15
A.1	Structure des principaux livrables	20
A.2	Glossaire	21

Introduction générale

La question centrale du projet :
un modèle qui prédit bien est-il forcément un modèle
juste ?

Pourquoi ce sujet est important

Les modèles de classification sont utilisés pour prendre ou aider à prendre des décisions : accepter un crédit, détecter une fraude, recommander un traitement, classer un dossier, estimer un risque. Dans un exercice classique de machine learning, on regarde surtout si le modèle prédit correctement. On calcule alors une accuracy, un F1-score ou une ROC-AUC.

Mais dans un contexte humain sensible, cela ne suffit pas. Imaginons deux groupes de personnes. Si le modèle se trompe rarement sur le premier groupe mais souvent sur le second, la moyenne globale peut cacher un vrai problème. Le modèle peut sembler bon sur le papier tout en créant une différence de traitement.

Pourquoi COMPAS

COMPAS est un outil utilisé aux États-Unis pour estimer le risque de récidive. Le dataset étudié ici vient de l'enquête de ProPublica sur les scores COMPAS. La cible `two_year_recid` indique si une personne a récidivé dans les deux ans. Les attributs sensibles étudiés sont principalement `race` et `sex`.

Point éthique majeur

Ce rapport ne dit pas qu'un algorithme doit décider seul dans un contexte judiciaire. Au contraire, il montre pourquoi ce serait dangereux. L'objectif est d'apprendre à auditer un modèle, pas à automatiser une décision de justice.

Objectifs pédagogiques

Objectifs du projet

1. Comprendre ce qu'est un biais algorithmique avec des mots simples.
2. Préparer un dataset réel en gardant une trace claire des choix de nettoyage.
3. Entraîner plusieurs modèles pour ne pas dépendre d'un seul résultat.
4. Comparer performance globale et performance par groupe.
5. Tester plusieurs méthodes de réduction de biais.
6. Formuler des recommandations concrètes et prudentes.

Chapitre 1

Comprendre le problème

Ce chapitre pose les bases. Il explique la classification, les erreurs d'un modèle et la différence entre performance et équité.

1.1 Qu'est-ce qu'un modèle de classification ?

Un modèle de classification reçoit des informations en entrée et doit choisir une classe en sortie. Dans ce projet, le modèle reçoit par exemple l'âge, le nombre d'antécédents, le type d'accusation et d'autres informations disponibles dans COMPAS. Il doit prédire une classe binaire :

- **0** : la personne n'est pas prédite comme récidiviste dans les deux ans ;
- **1** : la personne est prédite comme récidiviste dans les deux ans.

Exemple très simple

Si un modèle prédit la météo, il peut classer demain comme « pluie » ou « pas de pluie ». Ici, au lieu de la météo, le modèle classe une personne selon un risque de récidive. Comme le sujet touche à des humains, une erreur peut avoir des conséquences beaucoup plus graves.

1.2 Les quatre types de résultats

Pour comprendre les métriques, il faut comprendre la matrice de confusion. Elle compare la prédiction du modèle avec la réalité observée.

TABLE 1.1 – Lecture simple d'une matrice de confusion

Terme	Explication simple
Vrai positif (TP)	Le modèle prédit « risque » et la personne récidive réellement.
Faux positif (FP)	Le modèle prédit « risque » mais la personne ne récidive pas.
Vrai négatif (TN)	Le modèle prédit « pas de risque » et la personne ne récidive pas.
Faux négatif (FN)	Le modèle prédit « pas de risque » mais la personne récidive.

Pourquoi les faux positifs comptent beaucoup ici

Dans un contexte judiciaire, un faux positif peut signifier qu'une personne est considérée à risque alors qu'elle ne récidive pas. Si un groupe subit beaucoup plus de faux positifs qu'un autre, le modèle crée une différence de traitement.

1.3 Performance globale et fairness

La performance globale répond à la question : « Le modèle prédit-il souvent correctement ? » La fairness répond à une autre question : « Le modèle se trompe-t-il de manière comparable pour les différents groupes ? »

TABLE 1.2 – Différence entre performance et fairness

Aspect	Question posée	Exemple de métrique
Performance	Le modèle est-il bon en moyenne ?	Accuracy, F1-score, ROC-AUC
Fairness	Le modèle traite-t-il les groupes de manière comparable ?	DP, DI, EO, TPR, FPR
Interprétation	Peut-on faire confiance au résultat global ?	Analyse par groupe

Chapitre 2

Dataset COMPAS

Le dataset principal du projet est `data/raw/compas-scores-two-years.csv`. Il vient du dépôt public ProPublica et contient des informations liées à des personnes évaluées par COMPAS.

2.1 Source et taille

Le fichier brut téléchargé est `compas-scores-two-years.csv`. Après application des filtres de nettoyage et sélection des colonnes utiles, le dataset traité contient **6172 observations** et **12 variables**.

TABLE 2.1 – Fichiers de données utilisés

Fichier	Rôle	Statut
<code>data/raw/compas-scores-two-years.csv</code>	DatasetPrincipal brut	Pro- Pu- blica
<code>data/processed/compas_processed.csv</code>	DatasetPrincipal net- toyé et prêt pour l'au- dit	
<code>data/processed/dataset.csv</code>	DatasetDémonstration syn- thé- tique his- to- rique	secondaire uniquement

2.2 Variables importantes

TABLE 2.2 – Variables centrales de l’audit

Variable	Signification
<code>two_year_recid</code>	Cible à prédire : récidive observée dans les deux ans.
<code>race</code>	Attribut sensible utilisé pour l’audit des disparités raciales.
<code>sex</code>	Attribut sensible utilisé pour l’audit des disparités liées au genre.
<code>age</code>	Âge de la personne au moment de l’évaluation.
<code>priors_count</code>	Nombre d’antécédents judiciaires.
<code>c_charge_degree</code>	Niveau de l’accusation : délit ou crime selon le codage du dataset.
<code>decile_score</code>	Score COMPAS de risque, de 1 à 10.

2.3 Nettoyage réalisé

Le nettoyage vise à obtenir une base cohérente pour l’apprentissage automatique. Les lignes inutilisables sont retirées, les colonnes sont standardisées et les variables catégorielles sont préparées pour les modèles.

Règle importante

Les attributs sensibles ne disparaissent jamais du projet : même si on les retire des variables d’entrée du modèle, on les conserve pour mesurer les écarts de traitement. Sans eux, il serait impossible de vérifier si le modèle est injuste.

2.4 Limites du dataset

Un dataset judiciaire ne représente jamais parfaitement la réalité sociale. La variable `two_year_recid` dépend de ce qui a été observé, enregistré et poursuivi. Elle peut donc contenir des biais institutionnels ou historiques.

À retenir

Le label `two_year_recid` n’est pas une vérité absolue. Il décrit une récidive observée dans les données. Si l’observation elle-même est biaisée, le modèle peut apprendre une partie de ce biais.

2.5 Analyse exploratoire

La figure suivante résume les distributions principales par attribut sensible. Elle sert à repérer si les groupes sont équilibrés, si la cible varie fortement selon les groupes et si certains groupes ont très peu d’exemples.




FIGURE 2.1 – Distribution des labels par attribut sensible


Un groupe très petit donne des métriques fragiles. Par exemple, si un groupe contient une seule personne, une seule erreur peut faire varier une métrique de 0 à 1. Les conclusions solides doivent donc se concentrer sur les groupes suffisamment représentés.

Chapitre 3

Méthodologie expérimentale

3.1 Pipeline général

Le projet suit une chaîne complète, de la donnée brute au rapport final.



3.2 Découpage train, validation et test

Le dataset est découpé en trois parties :

- **Train** : sert à apprendre les paramètres du modèle.
- **Validation** : sert à comparer des réglages ou des seuils sans regarder le test final.
- **Test** : sert à mesurer les résultats finaux.

Quand c'est possible, le split est stratifié par une combinaison de la cible et des attributs sensibles. Cela évite qu'un groupe disparaisse accidentellement du test.

3.3 Modèles comparés

TABLE 3.1 – Modèles entraînés

Modèle	Idee intuitive	Pourquoi l'utiliser ?
Régression logistique	Trace une frontière simple entre les classes.	Baseline claire, rapide et interprétable.
Random Forest	Combine plusieurs arbres de décision.	Capte des relations non linéaires et robuste aux variables mélangées.
MLP	Petit réseau de neurones.	Vérifie si une approche neuronale améliore les résultats.

3.4 Deux politiques de features

Les modèles sont entraînés dans deux situations :

1. **with_sensitive** : les variables sensibles peuvent être données au modèle.
2. **without_sensitive** : les variables sensibles sont retirées des features, mais gardées pour l'audit.

Erreur fréquente

Retirer **race** ou **sex** des features ne garantit pas l'absence de biais. D'autres variables, comme le lieu, le type d'accusation ou les antécédents, peuvent être corrélées aux attributs sensibles et servir de proxys indirects.

3.5 Répétitions multi-seeds

Les expériences sont répétées avec les seeds **0, 1, 2, 3 et 4**. Une seed contrôle le hasard utilisé par certains algorithmes. Répéter l'expérience permet de vérifier si un résultat est stable ou s'il dépend d'un hasard favorable.

3.6 Intervalles de confiance

Le pipeline calcule aussi des intervalles de confiance bootstrap à 95% sur des métriques clés. L'idée est simple : au lieu de croire qu'un seul score est parfait, on estime une zone plausible autour du score.

Chapitre 4

Métriques utilisées

4.1 Métriques de performance

TABLE 4.1 – Métriques classiques

Métrique	Question simple	Attention
Accuracy	Quelle part des prédictions est correcte ?	Peut cacher les erreurs par groupe.
Précision	Quand le modèle dit « risque », a-t-il souvent raison ?	Important si les faux positifs sont graves.
Rappel / TPR	Parmi les vrais récidivistes, combien sont détectés ?	Important si les faux négatifs sont graves.
F1-score	Compromis entre précision et rappel.	Utile si les classes sont déséquilibrées.
ROC-AUC	Le modèle classe-t-il bien les risques du plus faible au plus fort ?	Ne suffit pas à juger la fairness.

4.2 Métriques de fairness

TABLE 4.2 – Métriques de fairness en langage simple

Métrique	Interprétation
Demographic parity (DP)	Compare les taux de prédiction positive entre groupes.
Disparate impact (DI)	Rapport entre les taux de sélection de deux groupes.
Equalized odds (EO)	Compare à la fois les TPR et les FPR entre groupes.
Equal opportunity	Compare surtout les TPR entre groupes.
FPR par groupe	Mesure la part de personnes non récidivistes classées à risque.
Selection rate	Part des personnes classées positives par le modèle.

Pourquoi Equalized Odds est centrale ici

Dans COMPAS, les erreurs n'ont pas toutes le même poids humain. Equalized odds est pertinente parce qu'elle regarde les faux positifs et les vrais positifs par groupe. Elle force à se demander : « le modèle fait-il le même type d'erreurs selon les groupes ? »

4.3 Lecture des écarts

Dans ce rapport, un écart proche de 0 est préférable. Un écart élevé signifie qu'il existe une différence importante entre groupes.

TABLE 4.3 – Lecture qualitative des écarts de fairness

Écart	Interprétation prudente
0.00 à 0.05	Écart faible.
0.05 à 0.15	Écart visible, à surveiller.
0.15 à 0.30	Écart important, nécessite analyse.
> 0.30	Écart très important, mitigation et justification nécessaires.

Chapitre 5

Résultats des modèles baseline

5.1 Résumé global

TABLE 5.1: Baselines multi-seeds : moyenne et écart-type

Politique	Modèle	Accuracy	F1-score	ROC-AUC
with_sensitive	logistic_regression	0.693	0.624	0.751
with_sensitive	mlp	0.686	0.623	0.750
with_sensitive	random_forest	0.692	0.630	0.755
without_sensitive	logistic_regression	0.692	0.624	0.748
without_sensitive	mlp	0.687	0.625	0.748
without_sensitive	random_forest	0.690	0.624	0.751

Lecture simple

Les modèles ont des performances proches. Les écarts-types multi-seeds restent faibles : environ 0.004 à 0.013 pour l'accuracy, 0.009 à 0.016 pour le F1-score et 0.005 à 0.010 pour la ROC-AUC. La meilleure ROC-AUC moyenne est obtenue par la forêt aléatoire avec attributs sensibles : environ 0.755. Cependant, l'écart est faible. En pratique, la régression logistique reste intéressante parce qu'elle est plus simple à expliquer.

5.2 Baseline principale retenue

La baseline principale utilisée pour les analyses détaillées est la régression logistique sans attributs sensibles directs, seed 0. Elle obtient :

TABLE 5.2 – Baseline principale

Métrique	Valeur
Accuracy	0.692
F1-score	0.625
ROC-AUC	0.751

5.3 Matrices de confusion et courbes ROC




FIGURE 5.1 – Matrices de confusion par groupe




FIGURE 5.2 – Courbes ROC par groupe

Interprétation

Ces figures montrent pourquoi un score global ne suffit pas. Deux groupes peuvent avoir une ROC-AUC correcte, mais des seuils ou erreurs différents. Il faut donc analyser le détail par groupe.

Chapitre 6

Analyse détaillée de fairness

6.1 Résultats par groupe

TABLE 6.1: Métriques détaillées par groupe

Attribut	Groupe	n	Base rate	Selection	TPR	FPR	Precision
race	African-American	467	0.535	0.495	0.652	0.313	0.706
race	Caucasian	319	0.379	0.235	0.421	0.121	0.680
race	Hispanic	89	0.326	0.247	0.517	0.117	0.682
race	Other	49	0.408	0.204	0.400	0.069	0.800
race	Asian	1	1.000	0.000	0.000	0.000	0.000
race	Native American	1	0.000	0.000	0.000	0.000	0.000
sex	Female	160	0.312	0.256	0.460	0.164	0.561
sex	Male	766	0.484	0.388	0.577	0.210	0.721

6.2 Lecture des résultats pour race

Le groupe **African-American** a un selection rate de 0.495, contre 0.235 pour le groupe **Caucasian**. Cela signifie que le modèle prédit presque deux fois plus souvent la classe positive pour le premier groupe dans le test.

Le FPR est aussi plus élevé : 0.313 pour **African-American**, contre 0.121 pour **Caucasian**. En mots simples, parmi les personnes qui ne récidivent pas, le modèle classe à risque une proportion beaucoup plus forte du premier groupe.

Point le plus préoccupant

L'écart de FPR sur **race** est important. Dans un contexte judiciaire, cela doit être traité comme un signal critique, parce que les faux positifs peuvent avoir des conséquences humaines lourdes.

6.3 Lecture des résultats pour sex

Les écarts liés à **sex** existent, mais ils sont moins élevés que ceux observés pour **race**. Le selection rate est de 0.256 pour **Female** et 0.388 pour **Male**. Le FPR est de 0.164 pour **Female** et 0.210 pour **Male**.

Cela ne veut pas dire qu'il n'y a aucun problème sur **sex**. Cela signifie seulement que, dans cette expérience, les disparités les plus fortes apparaissent sur **race**.

6.4 Résumé des écarts fairness

TABLE 6.2 – Écarts principaux de fairness sur la baseline

Attribut	DP diff	EO diff	FPR diff
race	0.495	0.652	0.313
sex	0.131	0.117	0.046

Conclusion de l'audit baseline

La baseline est acceptable en performance globale, mais elle n'est pas satisfaisante en fairness sur **race**. La suite du projet teste donc plusieurs méthodes pour réduire ces écarts.

Chapitre 7

Méthodes de mitigation

7.1 Pourquoi atténuer les biais

Une mitigation cherche à réduire les écarts entre groupes. Elle ne rend pas magiquement un système juste, mais elle permet de tester des compromis. Le but est de trouver une solution qui garde une performance utile tout en réduisant les disparités les plus problématiques.

7.2 Familles testées

TABLE 7.1 – Familles de mitigation comparées

Méthode	Principe simple	Moment d'action
Reweighting	Donner plus ou moins de poids à certains exemples.	Avant / pendant entraînement
Resampling	Rééquilibrer les couples groupe-label par duplication ou sous-échantillonnage.	Avant entraînement
Fairlearn	Entraîner sous contrainte de fairness.	Pendant entraînement
Adversarial PyTorch	Apprendre une représentation qui prédit la cible mais cache l'attribut sensible.	Pendant entraînement
Seuils par groupe	Ajuster le seuil de décision selon les groupes.	Après entraînement

Attention éthique sur les seuils par groupe

Modifier des seuils selon le groupe peut réduire certaines métriques, mais cette solution doit être justifiée juridiquement et éthiquement. Elle ne doit jamais être appliquée sans gouvernance, transparence et validation humaine.

7.3 Résultats des mitigations

TABLE 7.2: Comparaison des méthodes de mitigation

Attribut	Méthode	Accuracy	F1	DP diff	EO diff
race	reweighting	0.689	0.613	0.482	0.636
race	resampling	0.673	0.648	1.000	1.000
race	threshold	0.668	0.597	1.000	1.000
race	fairlearn_demographic_parity	0.552	0.353	0.255	0.316
race	fairlearn_equalized_odds	0.548	0.336	0.248	0.276
race	adversarial $\lambda = 0.0$	0.687	0.605	0.480	0.632
race	adversarial $\lambda = 0.1$	0.690	0.617	0.499	0.652
race	adversarial $\lambda = 0.5$	0.687	0.619	0.516	0.660
race	adversarial $\lambda = 1.0$	0.691	0.589	0.435	0.596
sex	reweighting	0.693	0.628	0.130	0.148
sex	resampling	0.684	0.647	0.142	0.180
sex	threshold	0.683	0.619	0.050	0.077
sex	fairlearn_demographic_parity	0.633	0.561	0.023	0.121
sex	fairlearn_equalized_odds	0.668	0.620	0.013	0.074
sex	adversarial $\lambda = 0.0$	0.685	0.603	0.132	0.167
sex	adversarial $\lambda = 0.1$	0.690	0.614	0.141	0.183
sex	adversarial $\lambda = 0.5$	0.691	0.651	0.083	0.152
sex	adversarial $\lambda = 1.0$	0.643	0.673	0.063	0.057




FIGURE 7.1 – Comparaison fairness avant et après mitigation

7.4 Interprétation

Pour **race**, Fairlearn réduit fortement les écarts DP et EO, mais au prix d'une baisse nette d'accuracy et de F1-score. Cela illustre le compromis classique : améliorer la fairness peut diminuer la performance globale si le dataset contient des déséquilibres importants.

Pour **sex**, Fairlearn et l'adversarial debiasing avec $\lambda = 1.0$ donnent des écarts beaucoup plus faibles. L'adversarial $\lambda = 1.0$ améliore même le F1-score, mais réduit l'accuracy. Le choix dépend donc de la métrique prioritaire.

Meilleur compromis prudent

Dans un contexte COMPAS, il est préférable de privilégier les méthodes qui réduisent Equalized Odds et FPR diff, même si l'accuracy baisse légèrement. Cependant, si la baisse de performance devient trop forte, la solution peut perdre son utilité opérationnelle.

Chapitre 8

Discussion critique

8.1 Pourquoi il n'existe pas une seule fairness

La fairness est un ensemble de définitions parfois incompatibles. Un modèle ne peut pas toujours satisfaire toutes les métriques en même temps, surtout si les groupes ont des base rates différents. Il faut donc choisir la métrique en fonction du contexte.

Dans un contexte judiciaire, Equalized Odds est plus pertinente que la simple parité démographique, car elle observe directement les erreurs. Ce qui compte n'est pas seulement le nombre de personnes classées positives, mais aussi qui est classé positif à tort.

8.2 Pourquoi l'accuracy peut tromper

Une accuracy autour de 0.69 semble correcte. Pourtant, elle ne dit pas si les erreurs sont équilibrées entre groupes. Un modèle peut avoir la même accuracy pour deux groupes, mais faire plus de faux positifs dans l'un et plus de faux négatifs dans l'autre. L'impact humain n'est alors pas le même.

8.3 Limites techniques

- Les groupes très petits produisent des métriques instables.
- Les résultats dépendent du split train/validation/test.
- Certaines méthodes de mitigation baissent fortement la performance.
- Les attributs sensibles peuvent être indirectement présents via des proxys.
- La causalité n'est pas démontrée : on observe des associations statistiques.

8.4 Limites éthiques

- Un modèle ne doit pas remplacer une décision humaine dans un domaine judiciaire.
- Un dataset historique peut contenir des biais de police, de poursuite ou d'enregistrement.
- Réduire une métrique de biais ne garantit pas la justice réelle.
- Les personnes concernées devraient pouvoir comprendre, contester et demander une révision humaine.

Chapitre 9

Recommandations

9.1 Recommandations techniques

À mettre en place avant tout usage sensible

1. Toujours publier les métriques globales et les métriques par groupe.
2. Suivre TPR, FPR, selection rate, precision et F1-score pour chaque attribut sensible.
3. Répéter les expériences avec plusieurs seeds.
4. Documenter les choix de seuils et les compromis performance/fairness.
5. Tester Fairlearn et adversarial debiasing, mais ne pas retenir une méthode seulement parce qu'elle diminue une métrique.
6. Ajouter un monitoring si le modèle est réutilisé sur de nouvelles données.

9.2 Recommandations de gouvernance

Gouvernance indispensable

- Mettre en place une validation humaine pour toute décision sensible.
- Prévoir une procédure de contestation.
- Expliquer clairement les limites du modèle aux utilisateurs.
- Ne jamais présenter le score comme une vérité objective sur une personne.
- Réaliser un audit périodique, car les données peuvent changer avec le temps.

9.3 Recommandation finale

La meilleure décision n'est pas de chercher « le modèle parfait ». La meilleure décision est de mettre en place un système contrôlé : modèle documenté, métriques publiées, erreurs surveillées, seuils justifiés, supervision humaine et possibilité de recours.

Chapitre 10

Conclusion

Ce projet montre qu'un audit de biais doit aller beaucoup plus loin qu'un simple entraînement de modèle. Sur COMPAS, les modèles obtiennent une performance globale raisonnable, mais les écarts par groupe, surtout sur **race**, restent importants.

Le résultat principal est donc double :

1. **Côté performance**, les modèles sont utilisables pour une étude technique, avec une accuracy autour de 0.69 et une ROC-AUC autour de 0.75.
2. **Côté fairness**, les écarts observés interdisent toute conclusion naïve du type « le modèle est bon donc il est juste ».

La leçon essentielle est simple : dans un domaine sensible, un modèle doit être évalué avec deux regards. Le premier regarde s'il prédit correctement. Le second regarde pour qui il se trompe, comment il se trompe, et quelles conséquences ces erreurs peuvent avoir.

Annexe A

Annexes techniques

A.1 Structure finale du projet

TABLE A.1 – Structure des principaux livrables

Dossier / fichier	Rôle
<code>scripts/download_compas.py</code>	Téléchargement du dataset COMPAS.
<code>scripts/train_baseline.py</code>	Entraînement des modèles baseline.
<code>scripts/evaluate_fairness.py</code>	Évaluation des métriques de fairness.
<code>scripts/train_adversarial.py</code>	Entraînement adversarial PyTorch.
<code>scripts/run_all.sh</code>	Exécution complète reproductible.
<code>notebooks/01_...06_...</code>	Notebooks pédagogiques en six étapes.
<code>results/tables</code>	Tableaux CSV finaux.
<code>results/metrics</code>	Métriques JSON complètes.
<code>reports/latex</code>	Rapport LaTeX et PDF.
<code>slides</code>	Présentation Beamer et PDF.

A.2 Commandes de reproduction

```
1 # Depuis le dossier bias_audit
2 python scripts/download_compas.py
3 python -m src.audit_main --preset compas --data-path data/
   raw/compas-scores-two-years.csv
4 bash scripts/run_all.sh
```

A.3 Glossaire très simple

TABLE A.2 – Glossaire

Mot	Explication
Biais	Différence de traitement ou d'erreur entre groupes.
Attribut sensible	Variable liée à une caractéristique protégée, par exemple race ou sex .
Proxy	Variable qui ne nomme pas directement un attribut sensible mais peut lui être fortement liée.
Mitigation	Technique qui cherche à réduire un biais mesuré.
Faux positif	Prédiction positive alors que la réalité est négative.
Faux négatif	Prédiction négative alors que la réalité est positive.

Bibliographie

- [1] ProPublica, *Machine Bias / COMPAS analysis dataset*, 2016.
- [2] Hardt, Price, Srebro, *Equality of Opportunity in Supervised Learning*, NeurIPS 2016.
- [3] Kamiran, Calders, *Data preprocessing techniques for classification without discrimination*, Knowledge and Information Systems, 2012.
- [4] Zhang, Lemoine, Mitchell, *Mitigating Unwanted Biases with Adversarial Learning*, AIES 2018.
- [5] NIST, *AI Risk Management Framework*, 2023.