

Logo ENSA à renseigner

MINI-PROJET – 2025/2026

Audit de biais d'un modèle de classification

Étude du dataset COMPAS ProPublica

Module : Deep Learning / Fairness algorithmique

Réalisé par : À renseigner
Encadré par : À renseigner
Filière : Intelligence Artificielle et Cybersécurité
Année universitaire : 2025–2026

Résumé exécutif

Ce rapport audite un modèle de classification binaire appliqué au dataset COMPAS de ProPublica. L'objectif est de mesurer et d'atténuer les disparités liées à l'origine (**race**) et au genre (**sex**) avec des métriques de fairness : demographic parity, disparate impact, equalized odds, TPR/FPR et selection rate par groupe.

Le dataset traité contient **6172 observations** et **12 variables**. La baseline principale est `logistic_regression`, politique `without_sensitive`, seed 0. Ses scores sont : accuracy=0.692, F1=0.625, ROC-AUC=0.751.

Table des matières

Résumé exécutif	1
1 Introduction	5
2 État de l’art	6
2.1 Fairness algorithmique	6
2.2 Mitigation	6
3 Données COMPAS	7
4 Analyse exploratoire orientée biais	8
5 Méthodologie	9
6 Résultats baseline	10
7 Métriques par groupe	12
8 Atténuation des biais	13
9 Discussion	15
9.1 Compromis performance/fairness	15
9.2 Limites	15
10 Recommandations	16
11 Conclusion	17
A Annexes techniques	18

Table des figures

4.1	Distribution des labels par attribut sensible	8
6.1	Matrices de confusion par groupe	10
6.2	Courbes ROC par groupe	11
8.1	Comparaison fairness avant/après mitigation	14

Liste des tableaux

6.1	Résumé des baselines, moyenne multi-seeds quand disponible	10
7.1	Métriques de fairness par groupe	12
8.1	Comparaison des méthodes de mitigation	13

Chapitre 1

Introduction

Les modèles de classification utilisés dans des contextes sensibles peuvent être performants globalement tout en produisant des erreurs inégalement distribuées entre groupes. Dans COMPAS, la décision étudiée est la prédiction de récidive à deux ans. Les faux positifs sont particulièrement critiques : ils peuvent correspondre à des personnes prédites à risque alors qu’elles ne récidivent pas.

Chapitre 2

État de l’art

2.1 Fairness algorithmique

La fairness n’a pas une définition unique. La parité démographique impose des taux de sélection comparables, tandis qu’equalized odds exige des taux d’erreur comparables, notamment TPR et FPR.

$$P(\hat{Y} = 1 \mid A = a) = P(\hat{Y} = 1 \mid A = b)$$

$$TPR_a \approx TPR_b \quad \text{et} \quad FPR_a \approx FPR_b$$

2.2 Mitigation

Le projet compare des méthodes de pré-processing (reweighting, resampling), d’in-processing (Fairlearn reductions, adversarial debiasing PyTorch) et de post-processing (seuils par groupe).

Chapitre 3

Données COMPAS

Le dataset principal est `compas-scores-two-years.csv`. Les variables centrales sont `two_year_recid` pour la cible, `race` et `sex` pour l'audit, ainsi que `age`, `priors_count`, `c_charge_degree` et les scores COMPAS.

COMPAS est un cas réel à fort impact humain. Le rapport ne prétend pas que le label soit une vérité neutre : il peut contenir des biais de mesure, de collecte ou de procédure judiciaire.

Chapitre 4

Analyse exploratoire orientée biais




FIGURE 4.1 – Distribution des labels par attribut sensible

Chapitre 5

Méthodologie

Le protocole utilise un split train/validation/test stratifié par label et attributs sensibles quand les effectifs le permettent. Les expériences sont répétées avec les seeds 0, 1, 2, 3 et 4. Les variables sensibles sont conservées pour l’audit, même lorsqu’elles sont retirées des features du modèle.

Chapitre 6

Résultats baseline

Politique	Modèle	Accuracy	F1	ROC-AUC
with_sensitive	logistic_regression	0.693	0.624	0.751
with_sensitive	mlp	0.686	0.623	0.750
with_sensitive	random_forest	0.692	0.630	0.755
without_sensitive	logistic_regression	0.692	0.624	0.748
without_sensitive	mlp	0.687	0.625	0.748
without_sensitive	random_forest	0.690	0.624	0.751

TABLE 6.1: Résumé des baselines, moyenne multi-seeds quand disponible




FIGURE 6.1 – Matrices de confusion par groupe




FIGURE 6.2 – Courbes ROC par groupe

Chapitre 7

Métriques par groupe

Attribut	Groupe	n	Base rate	Selection	TPR	FPR	Precision
race	African-American	467	0.535	0.495	0.652	0.313	0.706
race	Caucasian	319	0.379	0.235	0.421	0.121	0.680
race	Hispanic	89	0.326	0.247	0.517	0.117	0.682
race	Other	49	0.408	0.204	0.400	0.069	0.800
race	Asian	1	1.000	0.000	0.000	0.000	0.000
race	Native American	1	0.000	0.000	0.000	0.000	0.000
sex	Female	160	0.312	0.256	0.460	0.164	0.561
sex	Male	766	0.484	0.388	0.577	0.210	0.721

TABLE 7.1: Métriques de fairness par groupe

Chapitre 8

Atténuation des biais

Attribut	Méthode	Accuracy	F1	DP diff	EO diff
race	reweighting	0.689	0.613	0.482	0.636
race	resampling	0.673	0.648	1.000	1.000
race	threshold	0.668	0.597	1.000	1.000
race	fairlearn_demographic_parity	0.552	0.353	0.255	0.316
race	fairlearn_equalized_odds	0.548	0.336	0.248	0.276
race	adversarial lambda=0.0	0.687	0.605	0.480	0.632
race	adversarial lambda=0.1	0.690	0.617	0.499	0.652
race	adversarial lambda=0.5	0.687	0.619	0.516	0.660
race	adversarial lambda=1.0	0.691	0.589	0.435	0.596
sex	reweighting	0.693	0.628	0.130	0.148
sex	resampling	0.684	0.647	0.142	0.180
sex	threshold	0.683	0.619	0.050	0.077
sex	fairlearn_demographic_parity	0.633	0.561	0.023	0.121
sex	fairlearn_equalized_odds	0.668	0.620	0.013	0.074
sex	adversarial lambda=0.0	0.685	0.603	0.132	0.167
sex	adversarial lambda=0.1	0.690	0.614	0.141	0.183
sex	adversarial lambda=0.5	0.691	0.651	0.083	0.152
sex	adversarial lambda=1.0	0.643	0.673	0.063	0.057

TABLE 8.1: Comparaison des méthodes de mitigation




FIGURE 8.1 – Comparaison fairness avant/après mitigation

Chapitre 9

Discussion

9.1 Compromis performance/fairness

Les résultats montrent que l'accuracy globale ne suffit pas. Les écarts de FPR, TPR et selection rate doivent être analysés groupe par groupe. Equalized odds est privilégiée pour COMPAS car elle explicite les erreurs potentiellement lourdes dans un contexte judiciaire.

9.2 Limites

Les limites principales sont la nature observationnelle du dataset, les critiques méthodologiques sur la construction des labels COMPAS, la sensibilité juridique des seuils par groupe et l'impossibilité de satisfaire simultanément toutes les définitions de fairness.

Chapitre 10

Recommandations

- **HIGH – Fairness** : Prioriser l’analyse TPR/FPR par groupe avant tout déploiement.
- **HIGH – Judicial risk** : Dans un cas type COMPAS, documenter explicitement les faux positifs par groupe.
- **HIGH – Fairness** : Prioriser l’analyse TPR/FPR par groupe avant tout déploiement.
- **HIGH – Governance** : Mettre en place un monitoring periodique accuracy, F1, DP, EO, TPR et FPR par groupe.
- **MEDIUM – Fairness** : Comparer reweighting, resampling et seuils de decision sur validation.
- **MEDIUM – Fairness** : Comparer reweighting, resampling et seuils de decision sur validation.
- **MEDIUM – Methodology** : Justifier le choix d’equalized odds comme critere principal quand les faux positifs/faux negatifs ont un impact humain fort.
- **INFO – Fairness** : Presenter ces valeurs avec les tableaux TPR/FPR/selection rate par groupe dans le rapport final.
- **INFO – Fairness** : Presenter ces valeurs avec les tableaux TPR/FPR/selection rate par groupe dans le rapport final.

Chapitre 11

Conclusion

Le projet fournit un audit reproductible de COMPAS, compare plusieurs modèles, mesure les biais par groupe et teste plusieurs familles de mitigation. La recommandation principale est de ne jamais déployer un modèle sensible sur la seule base de l'accuracy globale.

Annexe A

Annexes techniques

Les scripts principaux sont `scripts/download_compas.py`, `scripts/train_baseline.py`, `scripts/evaluate_fairness.py`, `scripts/train_adversarial.py` et `scripts/run_all.sh`.

Bibliographie

- [1] ProPublica, *Machine Bias / COMPAS analysis dataset*, 2016.
- [2] Hardt, Price, Srebro, *Equality of Opportunity in Supervised Learning*, NeurIPS 2016.
- [3] Kamiran, Calders, *Data preprocessing techniques for classification without discrimination*, Knowledge and Information Systems, 2012.
- [4] Zhang, Lemoine, Mitchell, *Mitigating Unwanted Biases with Adversarial Learning*, AIES 2018.
- [5] NIST, *AI Risk Management Framework*, 2023.