
Audit de biais d'un modèle de classification

Étude complète du dataset COMPAS ProPublica

Performance, fairness, mitigation et recommandations

KPADENOU Kossi Roland

Filière Intelligence Artificielle et Cybersécurité – Juin 2026

- 1 Contexte
- 2 Méthodologie
- 3 Résultats
- 4 Mitigation
- 5 Recommandations
- 6 Conclusion

Partie 1

Contexte et problématique



1

Pourquoi auditer un modèle ?

Question centrale

Un modèle qui prédit correctement en moyenne est-il forcément juste pour tous les groupes ?

Performance

- Accuracy
- F1-score
- ROC-AUC
- Qualité moyenne du modèle

Fairness

- Erreurs par groupe
- Faux positifs différenciés
- TPR/FPR par attribut sensible
- Impact humain des décisions

- Source : ProPublica, fichier réel `compas-scores-two-years.csv`.
- Cible : `two_year_recid`, récidive observée à deux ans.
- Attributs audités : `race` et `sex`.
- Taille après nettoyage : **6172 observations**.
- Usage : audit pédagogique, pas décision judiciaire automatisée.

Point éthique

Le label judiciaire n'est pas une vérité neutre : il peut refléter des biais de mesure, d'observation ou de procédure.


Partie 2

Méthodologie expérimentale



2

Pipeline expérimental



Robustesse

Les expériences sont répétées avec les seeds 0, 1, 2, 3 et 4 pour éviter de tirer une conclusion sur un seul hasard.

Modèles comparés

- Logistic Regression
- Random Forest
- MLP
- Avec et sans attributs sensibles

Métriques suivies

- Accuracy, précision, rappel, F1
- ROC-AUC
- Demographic parity
- Equalized odds
- TPR/FPR par groupe

Erreur fréquente

Retirer race ou sex des features ne suffit pas : des variables proxy peuvent porter une partie de l'information.

Partie 3

Résultats baseline



Performance globale

0.692

Accuracy baseline

0.625

F1-score

0.751

ROC-AUC

Lecture

La baseline prédit correctement une majorité de cas, mais ces scores ne disent pas encore si les erreurs sont réparties équitablement entre groupes.

Attribut	DP diff	EO diff	FPR diff
race	0.495	0.652	0.313
sex	0.131	0.117	0.046

Signal principal



Les écarts les plus préoccupants apparaissent sur race, surtout pour Equalized Odds et les faux positifs.

Groupe	n	Selection	TPR	FPR
African-American	467	0.495	0.652	0.313
Caucasian	319	0.235	0.421	0.121
Female	160	0.256	0.460	0.164
Male	766	0.388	0.577	0.210

En mots simples

Le modèle classe beaucoup plus souvent certains groupes en risque positif, et il produit davantage de faux positifs sur certains groupes.

Visualisations clés



Partie 4

Réduction des biais



- **Reweighting** : pondérer les exemples.
- **Resampling** : rééquilibrer les couples groupe/label.
- **Fairlearn** : entraîner sous contrainte de fairness.
- **Adversarial PyTorch** : cacher l'attribut sensible dans la représentation.
- **Seuils par groupe** : ajuster la décision après entraînement.

Attention

Une mitigation doit être jugée sur deux axes : baisse du biais et maintien d'une performance utile.

Attribut	Méthode	Acc.	F1	EO diff
race	baseline	0.692	0.625	0.652
race	fairlearn EO	0.548	0.336	0.276
race	adversarial $\lambda = 1.0$	0.691	0.589	0.596
sex	baseline	0.692	0.625	0.117
sex	fairlearn EO	0.668	0.620	0.074
sex	adversarial $\lambda = 1.0$	0.643	0.673	0.057

Partie 5

Recommandations et limites



Recommandations principales

1. Ne jamais conclure avec l'accuracy seule.
2. Publier les métriques par groupe : TPR, FPR, selection rate, precision.
3. Prioriser Equalized Odds pour les contextes où les erreurs ont un impact humain.
4. Garder une supervision humaine et une procédure de contestation.
5. Documenter les limites du dataset COMPAS et des seuils utilisés.

Données

- Labels judiciaires imparfaits
- Groupes minoritaires très petits
- Corrélations et proxys

Méthodes

- Fairness multiple et parfois incompatible
- Mitigation parfois coûteuse en performance
- Pas de preuve causale

Partie 6

Conclusion



Conclusion

Un modèle peut être statistiquement utile et socialement risqué. L'audit doit donc répondre à deux questions : **est-ce que le modèle prédit bien ?** et **pour qui se trompe-t-il le plus ?**

Performance + Fairness + Gouvernance = IA responsable

Merci

Questions / discussion

KPADENOU Kossi Roland