

Audit de biais d'un modèle de classification

Étude du dataset COMPAS ProPublica

Réalisé par : À renseigner

Encadré par : À renseigner

Filière Intelligence Artificielle et Cybersécurité

18 juin 2026

- 1 Contexte
- 2 Méthodologie
- 3 Résultats
- 4 Mitigation
- 5 Conclusion

Question centrale

Le modèle prend-il des décisions équitables entre groupes sensibles, et comment réduire les disparités sans détruire la performance ?

- Cas réel : prédiction de récidive à deux ans.
- Attributs audités : race et sex.
- Risque majeur : faux positifs différenciés selon les groupes.

- Source : ProPublica, `compas-scores-two-years.csv`.
- Cible : `two_year_recid`.
- Variables : âge, antécédents, type d'accusation, score COMPAS.
- Limite : les labels judiciaires ne sont pas une vérité sociale neutre.

Pipeline expérimental

- 1 Nettoyage COMPAS et EDA orientée biais.
- 2 Split train/validation/test stratifié.
- 3 Baselines : Logistic Regression, Random Forest, MLP.
- 4 Audit : DP, DI, EO, TPR/FPR, selection rate.
- 5 Mitigation : reweighting, resampling, Fairlearn, PyTorch adversarial, seuils.

Pourquoi garder les attributs sensibles ?

Point critique




Retirer race ou sex des features ne prouve pas l'absence de biais : d'autres variables peuvent agir comme proxys.

Performance baseline

Métrique		Valeur
Accuracy		0.692
F1-score		0.625
ROC-AUC		0.751
Baseline	logistic_regression	

Attribut	EO diff	DP diff
race	0.652	0.495
sex	0.117	0.131

Visualisations



- **Reweighting** : pondération par couples groupe/label.
- **Resampling** : équilibrage des sous-groupes.
- **Fairlearn** : contraintes demographic parity/equalized odds.
- **Adversarial PyTorch** : représentation moins informative sur l'attribut sensible.
- **Post-processing** : seuils par groupe, à discuter éthiquement.

- Ne jamais se limiter à l'accuracy globale.
- Auditer systématiquement TPR/FPR par groupe.
- Privilégier equalized odds pour les erreurs en contexte judiciaire.
- Documenter les limites COMPAS et surveiller la dérive après déploiement.

Message clé

Un modèle peut être statistiquement utile et socialement problématique. L'audit doit donc combiner performance, fairness, mitigation et gouvernance.